ChatGPT

执行摘要

吴恩达在Agentic AI课程中指出，LLM作为评价者时不能简单地用1–5分的Likert尺度打分 [1] （这一观点在配套资料中也明确强调：不要使用1–5量表，LLM**校准不足**，应使用二元判断 [1] ）。我们调研发现，大量学术和工业证据都表明：让LLM给数值评分往往不可靠，其输出受校准、随机性和提示格式影响较大，评估分数与人工标注的一致度常低于预期；二元或多类判定、两两比较、人工审核或任务专用指标通常更稳健。本文综述相关文献和实践经验，分析LLM打分的局限、典型失效模式，并提出改进建议与替代方案。

1. 吴恩达观点及来源

吴恩达强调：**严格的评价流程是成功构建智能体工作的关键** [2] 。在Agentic AI课程的评估环节，他建议避免让LLM直接给出1–5分等连续评分，而是采用明确、可判定的评估标准（例如Yes/No判断） [1] [3] 。配套教材也提醒：“不要使用1–5量表（LLM校准不足），应使用二元准则” [1] 。这一观点暗合业界观察：LLM对数值尺度**缺乏自然校准**，1–5分之间的差异可能因提示细节、模型版本和采样随机性而波动 [3] [4] 。

2. 学术研究综述

- **一致性与相关性评测**：多篇论文对LLM打分与人工评价的一致性做了量化分析。Lee等人发现，不同评分刻度会显著影响人-机评分的一致性，综合来看使用0–5刻度比0–10更稳定 [5] 。Haldar等研究了LLM自评的一致性，用Krippendorff’s Alpha度量LLM多次打分的稳定性。结果表明，即使最佳模型（如Qwen 3）的Alpha也只有约0.56，GPT-4约0.40，远低于人类常规0.8的阈值 [6] [7] ，说明LLM评估具有较高随机性和波动。
- **人机相关性**：在SummEval等主观评分任务上，多项研究报告LLM评分与人工的相关系数通常只有中等水平。Yan等人发现，GPT-3.5 Turbo对摘要质量的评分与专家平均分的Spearman相关约为0.30–0.60 [8] ，而专家之间可达0.8–0.9。又如在一致性评价任务中，GPT-3.5的相关性仅为0.27–0.46 [9] 。总体而言，LLM能识别一般趋势（优于BLEU、BERTScore等自动指标），但在细粒度主观判断上仍与人类存在显著差距 [10] [9] 。
- **可靠性指标**：许多研究建议使用校正一致度指标而非简单准确率。例如在SummEval评分实验中，GPT-4评估与人评估的准确率约0.67，但Krippendorff’s Alpha仅约0.40 [6] 。当使用Kappa/Alpha等度量时，LLM与人类或自身的一致性往往明显低于表面准确率 [11] [7] ，提示我们单纯看“分数相等”容易高估模型的一致性。
- **定量实验**：Arize团队直接测试了GPT-4、Claude、Mixtral对0–10量表评分的稳定性，结果表明LLM输出分数常出现截断和饱和：如GPT-4对错误率超过10%的文本均返回满分10分 [12] ，不反映真实差异。该组总结：三个模型对连续范围的处理都“不够好”，不宜用于数值评分 [4] [12] 。链式思考和多次投票被证明能略微改善一致性，但整体趋势仍是不可靠。

3. 工业和开源案例

- **专家观点（博客/报告）**：Galileo AI的技术博客指出，很多团队犯的错误就是要求LLM返回0–100或1–10评分，这会牺牲一致性 [13] 。他们推荐把评价问题拆分为多个Yes/No判断，实验显示二元评判比连续评分在准确率上提升了23% [14] 。Arize的测试报告也表明，在多个LLM和小众任务上，数值评分输出大不稳定，轻微提示变化就会导致大幅分数波动 [4] 。Evidently等公司也建议避免使用含糊的数字区间，而应定义清晰类别或二元标准 [15] 。
- **行业工具和项目**：Anthropic、OpenAI等研发中强调混合手段来提高评估质量。例如Anthropic内部文档强调**多次试验/投票**、**校准提示**和**结合测试**来增强稳定性（他们定义了“trial”、“grader”等概念，并建议多次运行以平滑随机性 [16] ）。LangChain/AutoGen等社区框架中也普遍推荐多模型投票、链式

思考验证以及必要时人工复核来避免单次LLM评价的偏差。开源Benchmark如CodeJudgeBench针对代码任务发现：LLM评价存在**显著随机性**，不同输出顺序会改变排序结果，且点评分(low-shot)不如成对比较准确 [17] 。**两两比较**（让LLM判断A与B哪好）通常比分值评级更稳健。

4. 任务领域与常见失效模式

- **领域差异**：在客观可测任务（如数学、逻辑推理、闭式问答）中，LLM往往能输出一致性较高的判定，因为存在明确正确答案（例如上面提到的“自我偏好”研究使用数学题作为基准 [18] ）。但在开放式主观任务（摘要质量、创意写作、翻译等）中，由于评价标准模糊，一致性显著下降 [8] [9] 。专业领域（医疗、法律、金融等）对领域知识敏感：LLM可能缺乏最新或专业背景，易误判。许多研究(如医疗Q&A场景）表明，LLM答案的用户满意度常与客观质量指标**无相关** [19] ，提醒不要盲目信任LLM自评。
- **错误模式**：常见失效包括：LLM**过度自信/校准不足**，即相似回答分数不稳定 [3] [4] ；**采样随机性**导致同一回答多次打分不一致 [20] [11] ；**提示敏感性**和**锚定效应**（如位置变化或标度变化极大影响评分） [3] [11] ；**幻觉**（回答逻辑合理但不准确时难以检测）；**缺乏领域专业性**导致评判盲点；以及**主观评分标准不明晰**令LLM难以权衡。当LLM被要求给细致分数时，更容易“躲在中间值”而逃避决断，降低评估信号强度。

5. RAG问答实例与发现

在我们自己的RAG（检索增强生成）问答项目中观察到：当使用通用LLM来评估答案时，经常出问题。比如涉及专业细节的问题（医疗诊断、法律分析等），LLM往往**无法区分高质量与糟糕回答**，因为对领域知识掌握有限。其表现为在提供部分正确证据时给出过高评分，而在真正遗漏关键信息时却给出误导性高分。为检测这种问题，可比较LLM评分与一些客观指标（例如答案中引用文献的可靠度、与检索结果的一致性），或设置信心阈值：当LLM评分不合理地偏高时触发人工复核。缓解方法包括引入专门的领域校准模型（如医疗领域专用LLM）、要求LLM给出**链式思考解释**（并检查解释中的漏洞）、或者使用更严格的二元标准来判断“答案是否可信”而不是给细分分值。总之，在高度专业化场景中，需要人工/工具的辅助验证，不能完全依赖LLM自评。

6. 实践建议与替代方案

- **优化提示**：使用明确的评估提示和范例。先让LLM链式思考回答（要求列出判断依据）再打分，可提高可信度。避免模糊的“评出1–5分”，而用“是否满足某个条件”（是/否）或给出具体类别（Excellent/Good/Fair/Bad）等描述性评价。
- **多轮/投票**：单次调用结果不可信任，建议对同一输出进行多次评估并取多数票或平均，能显著提高稳定性 [21] [22] 。关闭随机采样（温度=0）可减少变异，但可能牺牲质量，需要结合使用。
- **校准与链式思考**：利用Few-shot或Chain-of-Thought提示，让LLM对评分标准进行自我判断，有助于“校正”评分尺度。研究显示引入引导语或让模型先自问自答可略微提升性能 [23] [24] 。
- **多模型集成**：可让不同LLM或同模型的不同版本分别评判，然后聚合结果。层叠使用较小模型做初筛、大模型做最终判断往往性价比更高 [25] [26] 。
- **人工/工具介入**：对于高风险任务，引入人工复核或使用专门工具检测（如事实核对系统、专业知识库、代码执行器等）。例如QA时可调用外部验证（如查询原始文献或执行计算）来辅助评分。对于代码生成可用自动测试来代替开放式评分。
- **评估流程设计**：建立完整的评估流水线：对模型输出进行分级检查——先做二元过滤（如基本是否回答）、再做多维度检查（如正确性、完整性、可读性等），最后汇总成最终结论。流程示例（Mermaid流程图）：

```
flowchart LR
  A[用户提问] --> B[文档检索(检索增强)]
  B --> C[LLM生成答案]
  C --> D{评分流程}
  D --> E[二元检查：回答是否包含主要信息？(是/否)]
```

```
D --> F[多维评分：正确性/完整性/流畅性（多项Yes/No)]
E --> G{是否通过}
F --> G
G -->|是| H[答案合格]
G -->|否| I[人工复核或重新检索]
I --> H
```

- **替代评估方法**：在很多场景下，**两两比较**优于直接打分：让LLM选择哪个答案更好（pairwise）能避免刻度不一致问题 [17] [10]。当评价尺度必须是离散时，使用明确定义的标签集（如“完全正确/部分正确/不正确”）而非模糊数字，更利于复现和解释。自动化指标（如BLEU、METEOR等传统指标）可用于早期过滤，但往往不足以覆盖高级需求。

7. 关键文献/报告一览表

参考文献	方法	任务/数据集	指标	主要结论
Lee et al. (2026) [5]	LLM作为评估器，不同刻度下人机一致性（6基准）	主观/客观任务混合	ICC(绝对一致性)	0–5刻度下人机一致性最高，0–10一致性最低；不同任务间刻度效应差异明显。
Haldar & Hockenmaier (2025) [11]	LLM评估的一致性测试（SummEval、MT-Bench）	摘要一致性、多维评分	Krippendorff’s α	LLM自评稳定性差：即使GPT-4，α仅≈0.40，远低于人类(≈0.48)；多次投票和更大模型能提高一致性。
Li et al. (2025) [27] [28]	LLM定制评估研究（问答、故事、数学）	常规NLP生成和推理任务	相关系数 (Pear/Spear)	LLM评估者能给出有效指标，但在复杂标准（如数理推理正确性）下易漏判或错判；对主观评价时部分合理但存在偏差。
Yan (2023) [8] [9]	GPT-3.5对摘要质量的评估分析	SummEval/FRANK摘要一致性	Spearman ρ	GPT-3.5评分与人类相关性低：ρ约0.30–0.60（SummEval overall），一致性维度ρ≈0.27–0.46；优于ROUGE等但比专家差距大。
代码JudgeBench (2025) [17]	26个LLM对代码生成/修复/单测的评估	代码生成与修复任务	分类准确率（对比）	“Pairwise”对比优于单输出打分；所有模型评估结果仍有随机性，输出顺序影响大；强调使用二元/排序评价。
业界博客：Evidently (2023) [15]	经验总结	各类LLM评估案例	—	建议：数字量表往往难以稳定工作，LLM评分**未校准**且易波动；推荐使用二元或明确类别答案来替代连续评分。

参考文献	方法	任务/数据集	指标	主要结论
业界博客：Galileo (2026) [3] [29]	LLM评估实践错误分析	举例实验（参考研究）	—	“8与9的差别取决于模型版本和随机性”；实验证明二元Yes/No问句较0–100打分在准确性上提升23%；**多次投票**也能改善结果。
业界博客：Arize (2024) [4] [12]	LLM数值评估可靠性测试	文本相关性和情感打分	—	实验表明GPT-4/Claude/Mixtral对0–10评分**不稳定**，小提示改动结果大；GPT-4对高错误率文本均给出满分10，说明无法处理连续比例；建议不要使用数值评分。

8. 评估方法对比表

评估方法	优点	缺点
1–5/0–10打分	表示细粒度直观，易收集统计数据	**高度主观且易波动**：LLM校准差、输出不一致；评级标准常模糊；难解释结果；需大量样本消噪。
两两比较（Pairwise）	模型只需判断“哪个答案更好”，避免直接量化；消除单一评分尺度偏差	需要提供可比较的两个备选输出；不能直接给量化分数；对多方案对比成本高（组合爆炸）。
二元/多类评价	判定明确，一致性高：是/否或Few类别易重复；可与清晰标准对应	信息量少，只给出粗略结论；对边界情况处理欠佳（例如介于好坏之间）；需要设计合理准则。
自动化指标	可快速计算，针对特定任务（如BLEU、F1）有明确定义；无需人力	多数指标针对特定场景，对开放生成缺乏语义理解；无法覆盖复杂语用和多模态质量；常与人为评分不一致。

注意：**假设与未指定因素** – 本报告未指明RAG数据规模、领域和具体模型。实践中，上述建议需根据领域难度和评估规模调整：数据量大时可尝试少量人工标注做基准，领域越专业则越应依赖专门知识或工具，模型越不稳定则投票和手工校验需求越高。

参考资料：引文中【…†L..】标注了对应来源段落，包括研究论文和官方/业界报告。每条关键结论均参照了这些权威来源。

---

[1] Finalize Your Evals Skill | Agent Factory
https://agentfactory.panaversity.org/docs/Building-Agent-Factories/evals-agent-performance/finalize-your-evals-skill

[2] Build Your Evals Skill | Agent Factory
https://agentfactory.panaversity.org/docs/Building-Agent-Factories/evals-agent-performance/build-your-evals-skill

[3] [13] [14] [20] [21] [25] [26] [29] Are You Making These 7 LLM-as-a-Judge Mistakes? | Galileo
https://galileo.ai/blog/why-llm-as-a-judge-fails

[4] [12] Why You Should Not Use Numeric Evals for LLM As a Judge - Arize AI
https://arize.com/blog-course/numeric-evals-for-llm-as-a-judge/

[5] Grading Scale Impact on LLM-as-a-Judge: Human-LLM Alignment Is Highest on 0-5 Grading Scale
https://arxiv.org/html/2601.03444v1

[6] [7] [11] [22] Rating Roulette: Self-Inconsistency in LLM-As-A-Judge Frameworks
https://arxiv.org/html/2510.27106v1

[8] [9] [10] [23] [24] Evaluating the Effectiveness of LLM-Evaluators (aka LLM-as-Judge)
https://eugeneyan.com/writing/llm-evaluators/

[15] F.A.Q on LLM judges: 7 questions we often get
https://www.evidentlyai.com/blog/llm-judges-faq

[16] Demystifying evals for AI agents \ Anthropic
https://www.anthropic.com/engineering/demystifying-evals-for-ai-agents

[17] [2507.10535] CodeJudgeBench: Benchmarking LLM-as-a-Judge for Coding Tasks
https://arxiv.org/abs/2507.10535

[18] Do LLM Evaluators Prefer Themselves for a Reason?
https://arxiv.org/html/2504.03846v2

[19] Evaluating the performance of large language models versus human researchers on real world complex medical queries | Scientific Reports
https://www.nature.com/articles/s41598-025-21689-w?error=cookies_not_supported&code=2ef874c4-a715-4c5e-800c-35c99d192072

[27] [28] Exploring the Reliability of Large Language Models as Customized Evaluators for Diverse NLP Tasks
https://aclanthology.org/2025.coling-main.688.pdf